시계열 예측 비교실험
공통 데이터·평가 기준

GECOS 논문을 바탕으로 정리한 모델 공통 실행 안내
Milan-900-10min / 버전 1.0 / 2026-10-14

이 문서는 서로 다른 시계열 예측 모델이 같은 예측 문제를 풀고 같은 기준으로 평가받도록 데이터와 평가 절차를 정리한 안내서입니다. 특정 모델의 네트워크 구조나 학습률·배치 크기를 정하는 문서는 아닙니다.

공통 항목	기본 비교 기준
대상	밀라노 중심부 900개 격자 셀의 Internet activity
기간·간격	2013-11-01 00:00부터 11-30 23:50까지, 현지 시각 10분 간격
예측 과제	각 셀의 직전 8개 관측값으로 다음 10분 구간의 값 1개 예측
분할	학습 11/01-20, 검증 11/21-25, 평가 11/26-30
정규화	셀별 min-max. 계수는 학습 20일로만 계산하고 이후 고정
결측	보간하지 않음. 입력 8개와 타깃이 모두 유한한 표본만 공통 평가
주지표	원래 데이터 척도의 셀별 MAPE(%)를 900셀 동일 가중으로 평균
보조·반복	셀별 평균 MAE, 전체 표본 MAE, 시드 53·54·55의 대응 비교

논문에서 가져온 틀과 이번에 명확히 정한 규칙

논문 [1]의 30일 자료, 10분 간격, 첫 20일 학습, 입력 길이 8, MAPE·MAE 평가를 기준으로 삼았습니다. 논문이 자세히 정하지 않은 5일/5일 검증·평가 분할, 정규화의 fit 범위, 결측·0값 처리와 집계 방식은 재현 가능한 공통 규칙으로 명문화했습니다. 모든 세부가 논문에 그대로 기재되어 있다는 뜻은 아닙니다.

읽는 순서: 데이터 정의(2쪽) → 전처리(3쪽) → 분할·예측(4쪽) → 결측(5쪽) → 지표(6쪽) → 선택·반복(7쪽) → 결과 형식(8쪽) → 계산 예제(9쪽) → 논문과의 대응(10쪽).

02 데이터의 대상과 시간축

무엇을 예측하는가

Telecom Italia의 공개 밀라노 통신 활동 데이터 중 Internet activity를 사용합니다. 이 값은 10분 구간의 인터넷 관련 통신 활동을 나타내는 수치입니다. 물리적 바이트·MB 또는 실제 접속 건수로 임의 환산하지 않습니다. 따라서 MAE의 단위는 "원 데이터의 활동량 단위"로 표기합니다. 시간 구간의 의미와 활동량 정의는 공개 데이터 설명 [2]를 따릅니다.

어느 셀을 사용하는가

현재 기본 비교의 공간 범위는 중심부 900셀로 고정합니다. 셀 ID는 다음 집합이며 오름차순으로 배열합니다. r과 c는 아래 ID 집합을 생성하기 위한 정수이며 위도·경도가 아닙니다. 논문 [1]은 중심 900셀을 설명하지만 이 정확한 ID 집합은 이번 비교에서 명시한 공통 선택입니다.

```
cell_id = 100*r + c
r = 40, 41, ..., 69;  c = 40, 41, ..., 69
```

예: 4040-4069, 4140-4169, 4240-4269, ..., 6940-6969. 각 구간은 양 끝을 포함하며 총 30×30=900셀입니다. 4040부터 6969까지의 모든 정수를 선택하는 것이 아닙니다. 10,000셀 확장 실험은 공간 범위가 다른 별도 실험으로 구분합니다.

시간대와 행 번호

항목	정확한 정의
표준 저장 시각	UTC 기준 Unix epoch 밀리초, 64비트 정수
날짜·요일 판단	Europe/Rome. 이번 2013년 11월은 UTC+01:00
첫 구간 시작	현지 2013-11-01 00:00 / UTC 2013-10-31 23:00 1383260400000 ms
마지막 구간 시작	현지 2013-11-30 23:50 / UTC 2013-11-30 22:50 1385851800000 ms
전체 배열	시간 4,320행 × 셀 900열. 시간·셀 ID 모두 오름차순
시간 인덱스	t=0부터 4319. timestamp(t)=1383260400000+600000×t

시각은 10분 구간의 시작을 표시합니다

00:00이라는 타임스탬프는 [00:00, 00:10) 구간의 활동량입니다. 마지막 23:50 구간은 다음 날 00:00에 끝납니다. UTC 날짜로 먼저 11월을 자르면 현지 월 경계가 달라지므로, Europe/Rome 기준으로 대상 기간을 선택합니다.

03 전처리: 집계와 정규화

1. 원시 기록에서 셀별 10분 값을 만듭니다

원시 파일은 탭으로 구분된 기록입니다. 공통 처리에 필요한 열은 셀 ID, 시간(밀리초), 국가코드, Internet 값입니다. 0부터 세는 열 번호는 각각 0, 1, 2, 7입니다. 같은 셀·시각에 서로 다른 국가코드의 행이 있을 수 있습니다. [2]

① 동일한 (셀 ID, 시각, 국가코드)가 중복되면 중복 입력 원인을 먼저 해결합니다. 중복 행을 그대로 더하지 않습니다. ② 선택한 900셀과 현지 11월의 10분 격자만 남깁니다. ③ 같은 (셀 ID, 시각)의 유한한 Internet 값들을 국가코드에 걸쳐 합산합니다. ④ 유한한 값이 하나도 없거나 행 자체가 없으면 NaN으로 둡니다.

일부 국가코드만 빈 값이면 나머지 유한한 값의 합을 사용합니다. 유한한 값 0은 관측된 0이며 결측이 아닙니다. 음수나 무한대 값은 데이터 오류로 처리합니다. 국가코드를 평균내거나, SMS·통화 열을 Internet 값에 더하지 않습니다. 이미 10분 자료이므로 시간 평균이나 시간별 재표본화도 하지 않습니다.

2. 셀마다 학습 20일의 최소·최대로 정규화합니다

y[t,i]를 집계된 원 활동량이라고 하겠습니다. 각 셀 i에 대해 t=0,...,2879 전체로 최소 lo_i와 최대 hi_i를 계산합니다. 첫 8개 관측도 학습기간에 속하므로 계수 계산에 포함합니다. 검증·평가 값을 min/max 계산에 넣지 않습니다.

```
lo_i = min(y[0:2880, i]);  hi_i = max(y[0:2880, i])
scale_i = hi_i - lo_i
if scale_i <= 1e-12: scale_i = 1
z[t,i] = (y[t,i] - lo_i) / scale_i
y_hat[t,i] = z_hat[t,i] * scale_i + lo_i
```

현재 기준 데이터는 학습 20일이 모두 유한합니다. 다른 데이터 버전에서 이 조건이 깨지면 임의의 보간·삭제로 계속하지 말고 데이터 차이를 확인합니다. 집계·계수·최종 지표 계산은 float64를 권장하며, 모델 입력을 float32로 바꿔도 평가 전 역변환은 같은 저장 계수를 사용합니다.

검증·평가 값이 0-1 범위를 벗어나도 그대로 둡니다

예를 들어 학습 최소 10, 최대 110이면 이후 관측 160의 정규화 값은 1.5입니다. 이를 1로 자르지 않습니다. 모델 예측도 임의로 0 이상으로 자르거나 범위를 제한하지 않습니다. 셀별 lo와 scale은 저장하고 모든 모델에서 동일하게 사용합니다.

이 문서의 기본 비교에서는 추가 로그 변환, 이상치 제거, 이동평균 평활화, 전체 셀 공통 스케일러를 적용하지 않습니다. 다른 변환을 연구하려면 공통 기준 결과와 구분한 추가 실험으로 기록합니다.

04 기간 분할과 한 시점 앞 예측

학습: 11/01-11/20	검증: 11/21-25	평가: 11/26-30

시간 순서를 유지합니다. 경계는 입력의 시작이 아니라 예측할 타깃 시각으로 정합니다.

용도	타깃의 현지 시각	0-based 타깃 인덱스
학습	11/01 01:20 - 11/20 23:50	8 ≤ t < 2880
검증	11/21 00:00 - 11/25 23:50	2880 ≤ t < 3600
평가	11/26 00:00 - 11/30 23:50	3600 ≤ t < 4320

학습에 허용된 관측기간 자체는 11/01 00:00부터입니다. 다만 첫 예측 타깃에는 앞선 8개 관측이 필요하므로 첫 타깃은 01:20이 됩니다. 날짜 경계에서 입력 창을 버리거나 각 분할의 처음 8개 타깃을 다시 제외하지 않습니다.

```
X[t,i] = [z[t-8,i], ..., z[t-1,i]]
target[t,i] = z[t,i]       # one next 10-minute interval
```

경계 시점의 구체적인 예

타깃 구간 시작	사용할 실제 관측 구간의 시작 시각
11/01 01:20	11/01 00:00, 00:10, ..., 01:10
11/21 00:00 (검증 첫 타깃)	11/20 22:40, 22:50, ..., 23:50
11/26 00:00 (평가 첫 타깃)	11/25 22:40, 22:50, ..., 23:50

각 예측은 해당 타깃 구간이 시작되기 직전에 수행한다고 가정합니다. 앞선 8개 구간의 실제 관측은 이미 알 수 있습니다. 다음 시점에는 새로 관측된 실제 값을 입력에 넣습니다. 이전 예측값을 되먹임하는 다단계 재귀 예측과는 다른 과제입니다.

검증·평가 구간의 과거 관측을 입력으로 사용하는 범위

t를 예측할 때 t 이전의 실제 관측만 사용할 수 있습니다. 앞선 평가 타깃이 이미 관측된 뒤 다음 예측의 입력이 되는 것은 허용됩니다. 그러나 검증·평가 정답으로 모델 가중치나 정규화 계수를 다시 학습하는 것은 허용하지 않습니다. 이는 고정 모델의 순차적 한 시점 앞 평가입니다.

검증과 평가의 역할을 분리합니다

검증 구간은 설정 및 checkpoint 선택에 사용합니다. 평가 구간은 모든 선택을 끝낸 뒤 성능 보고에만 사용합니다. 평가 결과가 좋았던 설정을 다시 고르거나, 검증 구간까지 합쳐 재학습한 결과를 이 기본 비교에 섞지 않습니다. 학습 표본의 미니배치 순서를 섞는 것은 가능하지만 시계열의 학습/검증/평가 행을 무작위로 분할하지 않습니다.

05 결측 처리와 공통 평가 표본

표본의 유효성은 데이터만으로 먼저 정합니다

셀 i, 타깃 t의 입력 8개와 정답 1개가 모두 유한한 경우에만 그 표본을 사용합니다. 이 조건을 valid_q8이라고 부릅니다. 마스크는 모델이나 예측값과 무관하게 같은 원자료에서 한 번 계산합니다.

```
valid_q8[t,i] = all(isfinite(y[t-8:t+1, i]))
MAPE_eligible[t,i] = valid_q8[t,i] and (y[t,i] > 0)
```

NaN을 0으로 바꾸지 않고 앞뒤 값 보간, 전방 채우기, 후방 채우기도 하지 않습니다. 결측 행을 시간축에서 삭제한 뒤 남은 행을 이어 붙이면 10분 간격이 깨지므로, 전체 시간축은 유지하고 해당 창만 제외합니다.

현재 900셀 기준 자료의 확인값

구간	후보 표본	유효 표본	제외
학습	2,584,800	2,584,800	0
검증	648,000	648,000	0
평가	648,000	647,438	562
합계	3,880,800	3,880,238	562

학습 후보는 (2880-8)×900, 검증과 평가 후보는 각각 720×900입니다. 원자료의 결측 셀-시점은 188개이며 11/29에 92개, 11/30에 96개입니다. 2개 셀에 결측이 있고, 평가 유효 표본 수는 셀에 따라 439-720개입니다. 여러 겹친 입력 창에 결측의 영향이 퍼지므로 188과 562는 서로 다른 수입니다.

현재 기준 배열의 유한한 값에는 정확히 0인 타깃이 없습니다. 그럼에도 다른 규모·버전의 자료에서 동일한 계산을 적용할 수 있도록 0 처리 규칙을 6쪽에 명시합니다. 위 수치는 논문에 보고된 결측 통계가 아니라 이번 공통 기준 데이터의 재검산값입니다.

예측 실패 때문에 평가 표본을 줄이면 안 됩니다

valid_q8=True인 표본에서 NaN·무한대 예측 또는 예측 누락이 생기면 실행 실패로 보고합니다. 그 행만 삭제해서 점수를 낮추지 않습니다. 모델별 유효 표본 수는 동일해야 합니다. 기본 비교를 완료하려면 모든 유효 타깃에 예측이 있어야 합니다.

더 긴 입력 길이를 쓰면 필요한 과거 범위와 결측 마스크도 달라집니다. 이 결과는 입력 길이 8의 기본 비교와 별도 표로 제시하고, 바뀐 입력·표본 수·마스크를 공개해야 합니다.

06 평가 지표: 원 척도와 셀별 평균

정규화된 예측은 먼저 셀별 계수로 역변환합니다. 아래 y와 pred는 모두 원 활동량 척도입니다. V_i는 셀 i의 유효 평가 시점, V_i+는 그중 y>0인 시점입니다. 각 셀의 점수를 먼저 계산한 뒤 셀을 동일 가중합니다.

```
MAE_i = mean(abs(y - pred))                  # t in V_i
MAPE_i_percent = 100 * mean(abs(y-pred) / y)  # t in V_i+
macro_MAE = mean(MAE_i)                      # equal cells
macro_MAPE_percent = mean(MAPE_i_percent)    # equal cells
MAPE_ratio = macro_MAPE_percent / 100
micro_MAE = sum(abs(y-pred)) / total_valid_rows
```

주지표와 보조지표

주지표는 raw macro MAPE(%)입니다. 보조지표로 raw macro MAE와 micro MAE를 반드시 함께 보고합니다. macro는 셀마다 같은 비중을, micro는 유효 표본마다 같은 비중을 줍니다. 셀별 유효 표본 수가 다르면 두 MAE는 다를 수 있습니다. 모델이나 임의 그룹의 평균을 다시 평균내지 말고 전체 셀 결과에서 집계합니다.

0 타깃, 작은 값, 잘못된 예측

정답 0은 MAE에 포함하고 MAPE에서만 제외합니다. 분모에 epsilon을 더하거나 작은 양수 정답을 임의로 제외하지 않습니다. 양수 타깃이 전혀 없는 셀은 MAPE가 정의되지 않으므로 MAPE 평균에서 제외하고 해당 셀 수를 반드시 보고합니다. 전체에 양수 타깃이 없으면 MAPE는 미정의입니다. 음수 타깃은 데이터 오류이고, 음수 예측은 자르지 않고 그대로 오차를 계산합니다.

손으로 확인할 수 있는 계산 예

셀	유효 정답 → 예측	MAE	MAPE
A	1→0, 2→3 (2개 표본)	1.0	75%
B	0→1, 4→2, 6→9 (3개 표본)	2.0	50%

A의 상대오차는 1과 0.5이므로 평균 75%입니다. B의 0 타깃은 MAPE에서 빠지고, 나머지는 모두 0.5이므로 50%입니다. 따라서 macro MAPE=62.5%, 비율값=0.625, macro MAE=(1+2)/2=1.5, micro MAE=(1+1+1+2+3)/5=1.6입니다.

0.10과 0.10%는 서로 다릅니다

MAPE 비율 0.10은 10%입니다. 결과표 열 제목에 MAPE(%)를 명시하고 비율을 같이 제공하면 단위 혼동을 피할 수 있습니다. 소수점 반올림은 지표를 모두 계산한 뒤 표시 단계에서만 수행합니다.

07 모델 선택과 반복 실험의 공정성

공통으로 고정할 것과 모델별로 기록할 것

구분	운영 규칙
공통으로 고정	셀·기간·타깃 시각, 입력 길이 8, 정규화 계수, 결측 마스크, 평가식, 반복 시드
모델별로 정하고 공개	모델명·버전, 구조, 학습률·배치 크기·손실, 학습 예산·종료 규칙, 탐색한 설정 수, 사전학습 사용 여부
기본 비교의 예측 입력	대상 셀의 직전 8개 Internet 관측값. 학습에는 같은 900셀의 학습기간을 사용할 수 있음
추가 정보 조건	다른 셀의 예측 입력, 외생변수, 더 긴 입력, 사전학습·온라인 갱신은 사용 범위를 공개하고 기본 조건과 구분해 보고

기본 비교의 학습·선택에는 20일까지의 학습자료와 별도의 검증자료만 사용합니다. 예측 타깃 시점의 실제 값을 입력으로 넣지 않습니다. 순환 모델의 숨은 상태나 특징 캐시가 창 밖의 과거 정보를 추가로 전달하는지도 확인하고, 기본 8개 입력 조건에서는 창마다 그 범위를 맞춥니다.

설정 선택은 검증 구간에서 끝냅니다

공통 선택 점수는 검증 구간의 정규화 척도 MAE입니다. 셀별 MAE를 계산한 뒤 동일 가중으로 평균하고, 점수가 가장 낮은 설정·checkpoint를 선택합니다. 같은 설정의 epoch 간 정확한 동률이면 이른 epoch를 사용합니다. 학습 손실과 평가의 주지표는 다를 수 있으므로 사용한 선택 점수를 명시합니다. 이번 검증 구간은 셀마다 720개 유효 표본이므로 전체 표본 평균과 셀별 평균이 같습니다.

학습 예산·조기 종료·하이퍼파라미터 탐색 횟수는 평가를 보기 전에 정하고 기록합니다. 다른 모델에 특정 모델의 학습률·배치 크기를 그대로 강요하지 않되, 특정 모델만 평가 결과를 보고 탐색 기회를 추가하지 않습니다. 평가 후 검증 구간까지 합친 재학습은 기본 비교에 포함하지 않습니다.

시드 53·54·55로 대응시켜 보고합니다

각 확률적 모델을 시드 53, 54, 55에서 반복합니다. 매번 난수 생성기와 모델 상태를 초기화하고, 같은 시드의 모델 간 차이를 나란히 계산합니다. 시드별 값, 3회 평균, 표본 표준편차(ddof=1)를 보고합니다. 서로 다른 구조에서 같은 시드는 같은 초기 가중치를 뜻하지 않습니다. 동일 시드가 GPU의 비트 단위 재현성까지 보장하지도 않습니다.

반복의 해석

3시드는 하나의 평가기간에 대한 학습 무작위성 반복입니다. 독립된 3개 기간 또는 자동으로 성립하는 99% 신뢰구간이 아닙니다. 결정적인 모델의 동일 결과를 복사한 경우 실제 실행 수와 재사용 수를 구분하고 독립 반복처럼 설명하지 않습니다.

08 팀 간 결과 교환 형식

예측 결과는 셀·타깃 시각으로 연결합니다

모델마다 최소한 다음 열을 가진 긴 형식의 CSV 또는 동등한 테이블을 저장합니다. 평가 후보 전체 648,000행을 시드마다 유지하면 결측 처리의 일치 여부를 쉽게 확인할 수 있습니다. 유효 예측은 정확히 647,438행이어야 합니다. (model_id, config_id, seed, cell_id, timestamp_utc_ms)가 행 식별 키입니다.

필드	의미와 규칙
model_id, config_id	모델과 확정 설정의 식별자. 구조·소프트웨어 버전은 별도 명세에 기록
seed, split	53/54/55와 evaluation 등 구간 이름
cell_id	원래 셀 ID. 배열 열 번호로 대신하지 않음
timestamp_utc_ms	예측할 구간의 시작 시각. 정수 밀리초이며 입력 마지막 시각이 아님
y_true_raw	집계 후 정규화 이전의 정답. 결측이면 빈 필드와 마스크로 표시
y_pred_raw	동일 원 척도의 예측. 유효 표본에서 누락·NaN·무한대 금지
valid_q8	입력 8개와 타깃의 공통 유한성 마스크
mape_eligible	valid_q8=True이면서 y_true_raw>0

요약 결과와 실행 명세

결과표에는 시드별 MAPE(%), MAPE 비율, macro MAE, micro MAE, 유효 행 수, MAPE 양수 타깃 수, MAPE에 포함된 셀 수와 0 타깃 수를 기록합니다. 셀별 표본 수와 지표도 저장합니다. 기준 모델과의 차이는 같은 시드끼리 계산하며 MAPE(%) 차이는 퍼센트포인트(%p), 상대 개선율은 %로 구분합니다.

실행 명세에는 데이터 버전·해시, 900개 ID와 타임스탬프 순서, 스케일러·마스크 해시, 코드·모델 버전, 선택 규칙, 시드, 실행 환경, 실패·재시도·재사용 여부를 포함합니다. 해시는 파일이 바뀌지 않았는지 확인하는 값입니다. 파일 형식이 다르면 파일 해시도 달라지므로 배열값·ID·시각의 동등성도 대조합니다.

시간·메모리 비교

전처리, 모델 준비·학습, 예측과 파일 입출력 시간을 구분하고 전체 비용도 보고합니다. 같은 장비·측정 구간에서 비교하며, GPU는 작업 완료를 동기화한 뒤 시간을 멈춥니다. 첫 실행과 캐시를 사용한 반복 실행을 구분합니다. GPU 전용 메모리와 시스템 RAM을 따로 기록하고 공유 메모리를 전용 VRAM에 더하지 않습니다. 다른 장비에서 얻은 논문 시간과 직접 속도 우위를 계산하지 않습니다.

09 참고 구현: 분할·창·평가

아래 NumPy 예제는 모델과 독립된 참조 계산입니다. y는 원 척도 float64 배열(4320,900), pred_raw는 평가기간의 원 척도 예측 배열(720,900)입니다. 모델은 이 문서의 같은 스케일러와 입력 창을 사용해야 합니다.

```
import numpy as np

# 1) Train-only scaling: keep the full timeline.
assert y.shape == (4320, 900)
assert np.isfinite(y[:2880]).all()
assert (y[np.isfinite(y)] >= 0).all()
lo = y[:2880].min(axis=0)
scale = y[:2880].max(axis=0) - lo
scale[scale <= 1e-12] = 1.0
z = (y - lo) / scale

# 2) A target t uses exactly t-8, ..., t-1.
def get_samples(a, b):
    ts, cells, xs, ys = [], [], [], []
    for t in range(a, b):
        good = np.isfinite(y[t-8:t+1]).all(axis=0)
        for i in np.flatnonzero(good):
            ts.append(t); cells.append(i)
            xs.append(z[t-8:t, i]); ys.append(z[t, i])
    return ts, cells, np.asarray(xs), np.asarray(ys)
# train: get_samples(8,2880); validation: (2880,3600)
# evaluation: (3600,4320). Keep cell_ids[cells] with ts.

# 3) Inverse-transform predictions before scoring.
# pred_raw = pred_scaled * scale[None,:] + lo[None,:]
truth = y[3600:4320]
mask = np.isfinite(truth).copy()
for lag in range(1, 9):
    mask &= np.isfinite(y[3600-lag:4320-lag])
assert mask.sum() == 647438
assert pred_raw.shape == truth.shape
assert np.isfinite(pred_raw[mask]).all()

# 4) Equal-cell macro metrics, plus pooled micro MAE.
err = np.zeros_like(truth)
err[mask] = np.abs(truth[mask] - pred_raw[mask])
count = mask.sum(axis=0)
assert (count > 0).all()
mae_cell = err.sum(axis=0) / count
positive = mask & (truth > 0)
npos = positive.sum(axis=0)
relative = np.zeros_like(truth)
relative[positive] = err[positive] / truth[positive]
ratio_cell = np.divide(relative.sum(axis=0), npos,
    out=np.full(900, np.nan), where=npos > 0)
eligible_cells = npos > 0
mape_pct = (100 * ratio_cell[eligible_cells].mean()
            if eligible_cells.any() else np.nan)
macro_mae = mae_cell.mean()
micro_mae = err.sum() / mask.sum()
```

예제의 단순 반복문은 이해를 위한 것입니다. 벡터화·배치 처리로 바꿔도 (셀 ID, 타깃 시각), 입력 창, 마스크와 최종 지표가 동일해야 합니다. 모든 제외 사유와 분모를 함께 저장합니다.

10 논문과의 대응 및 실행 확인표

논문의 내용 [1]	이번 비교 기준에서의 적용
첫30일, 10분 간격, 셀당4,320시점 IV-A, 인쇄6265쪽	2013년11월, 현지 시각 기준의 완전한10분 격자로 고정
중심900셀 및 전체10,000셀 실험 IV-A, 인쇄6265쪽	현재900셀의 정확한 ID를2쪽에 고정.10,000셀은 별도 규모로 검증
첫20일 학습, 뒤10일 검증·테스트 IV-A, 인쇄6265쪽	21-25일 검증과26-30일 평가로 분리.5/5는 공통 보완 규칙
기본 입력 길이 q=8, 간격10분 Table I와 본문, 인쇄6266쪽	직전8개 관측→다음10분 값1개.기간 경계에서 과거 입력 허용
MAPE 식(2), MAE 식(3) 인쇄6265-6266쪽	원 척도 MAPE(%)·MAE.셀 평균·0값·결측·반복 방식은 이 문서에서 명시

국가코드 집계 방식, 정규화 계수의 fit 범위, 결측 창과 0 타깃 처리, 정확한 셀 ID, 셀별 가중, 반복 시드와 결과 형식은 논문 본문만으로 완전히 결정되지 않는 세부입니다. 이 문서는 논문을 바탕으로 그 세부를 공통 비교 규칙으로 정한 것이며, 저자의 모든 구현 선택을 확인했다는 주장은 하지 않습니다.

논문 표의 점수와 새 실행의 점수는 구분합니다

검증·평가 세분, 전처리 및 평가 분모가 같다는 확인 없이 논문 표의 점수를 이번 모델의 점수와 직접 우열 비교하지 않습니다. 모든 비교 대상은 이 문서의 같은 데이터·마스크·평가식으로 점수를 산출해야 합니다. 또한 현재 평가기간은 연구 전체에서 미노출임을 보장하지 않으므로 회고적 비교로 해석합니다. 독립 일반화 확증에는 별도의 미사용 자료가 필요합니다.

실행 전과 결과 수합 때 확인할 사항

① ID900개·시간4320행·시간대가 일치하는가? ② 원시 집계와 학습기간 스케일러가 같은가? ③ 첫 타깃과 분할 경계 입력이 맞는가? ④ 평가 후보648,000개·유효647,438개가 일치하는가? ⑤ 역변환 후 같은 MAPE·MAE를 계산했는가? ⑥ 평가 전에 설정을 고정했는가? ⑦ 시드별 예측·선택 설정·실행 비용을 보존했는가?

참고문헌

[1] H. Yang, J. Park, S. M. Raza, M. Kim, M. Y. Chung, H. Choo. "Urban Mobile Data Prediction With Geospatial Clustering and Dual Residual Learning." IEEE Transactions on Network and Service Management, 22(6), 6260-6273, 2025. DOI: 10.1109/TNSM.2025.3599168.

https://doi.org/10.1109/TNSM.2025.3599168

[2] G. Barlacchi et al. "A multi-source dataset of urban life in the city of Milan and the Province of Trentino." Scientific Data 2, 150055, 2015. 공개 데이터의 Methods / Telecommunications activity / Data Records 설명. DOI: 10.1038/sdata.2015.55.

https://www.nature.com/articles/sdata201555