시계열 예측 비교실험
공통 데이터·평가 기준

Milan-900-10min / 버전 1.2 / 2026-10-23
논문·제공 자료 기반 재현 비교를 위한 모델 공통 안내

이전 문서와 비교해 바뀐 부분

v1.0과 v1.1의 20/5/5 조건을 이번 전달 기준에서 제거했습니다. 전체 30일 정규화와 뒤 10일 검증·평가 재사용을 적용하고, 실제 타깃 경계는 현재 재현 코드와 맞춥니다. 기존 10개 절의 흐름은 유지합니다.

항목	이전 v1.0·v1.1	개정 v1.2
정규화 03·09절	첫 20일로 셀별 min/max 계산	전체 30일의 유한 관측으로 셀별 min/max 계산. 뒤 10일의 극값도 반영
분할·타깃 04·05·09절	학습 20일 / 검증 5일 / 평가 5일	첫 20일 영역 학습 / 뒤 10일 영역 검증·평가. 제공 코드의 창 경계와 5시점 평가 오프셋 보존
평가 표본 05·08·09절	후보 648,000 / 유효 647,438	후보 1,284,300 / 유효 1,283,738. 평가 타깃은 검증 타깃의 부분집합
지표·선택 06·07·08절	셀 평균 macro MAPE 주지표, 셀 평균 검증 MAE	제공 최종 집계에 맞춘 micro MAPE 우선 보고. macro도 병기. checkpoint는 정규화 검증 표본 MAE
해석 01·04·10절	후속 비교용 5/5 분리 조건	제공 절차에 맞춘 재현 비교. 독립 시험으로 해석하지 않으며 논문 최종 실행 동일성은 미확정

그대로 유지하는 부분

Milan 중심 900셀, 2013년 11월, 10분 간격, 입력 8개로 다음 값 1개 예측, 결측 보간 없음, 같은 공통 마스크, 원 척도 오차, 반복 시드 53·54·55를 유지합니다. v1.1의 float64 계산, 네 지표 병기, 시드 평균과 앙상블 구분도 유지합니다.

이 문서는 특정 예측 모델의 구조·군집화 절차·가중치를 다루지 않습니다. 확인된 제공 구현과 논문 본문, 현재 재현을 위해 정한 규칙을 구분하며, 원저자의 최종 실험과 완전히 같다고 단정하지 않습니다.

구성: 변경 요약 1쪽 + 기존 순서의 본문 10개 절(2-11쪽).

01 공통 데이터·평가 기준 개요

이 문서는 서로 다른 시계열 예측 모델이 같은 예측 문제를 풀고 같은 기준으로 평가받도록 데이터와 평가 절차를 정리한 안내서입니다. 특정 모델의 네트워크 구조나 학습률·배치 크기를 정하는 문서는 아닙니다.

공통 항목	기본 비교 기준
대상	밀라노 중심부 900개 격자 셀의 Internet activity
기간·간격	2013-11-01 00:00부터 11-30 23:50까지, 현지 시각 10분 간격
예측 과제	각 셀의 직전 8개 관측값으로 다음 10분 구간의 값 1개 예측
분할	첫 20일 영역 학습, 뒤 10일 영역 검증·평가 재사용. 실제 타깃은 04절의 제공 코드 경계 적용
정규화	셀별 min-max. 전체 30일의 유한 관측으로 계산하고 고정
결측	보간하지 않음. 입력 8개와 타깃이 모두 유한한 표본만 공통 평가
주지표	원 척도의 유효 양수 타깃 전체를 같은 비중으로 평균한 micro MAPE(%)
보조·반복	micro MAE, macro MAPE, macro MAE. 시드 53·54·55 대응 비교

논문·제공 구현·현재 규칙의 구분

논문 [1]은 30일 자료, 첫 20일 학습과 뒤 10일 검증·테스트, 입력 길이 8을 설명합니다. 제공 파일에서 확인한 전체 30일 정규화·뒤 10일 재사용·타깃 경계를 이번 공통 기준으로 채택합니다. 뒤 10일을 5일씩 나누지 않습니다. 저자의 최종 입력 CSV와 실행 이력은 확인되지 않았으며, 결측·0값·float64 계산·반복 시드 등 현재 명시한 규칙까지 논문이 모두 정했다고 주장하지 않습니다.

읽는 순서

데이터 정의(3쪽) → 전처리(4쪽) → 분할·예측(5쪽) → 결측(6쪽) → 지표(7쪽) → 선택·반복(8쪽) → 결과 형식(9쪽) → 계산 예제(10쪽) → 논문과의 대응(11쪽).

02 데이터의 대상과 시간축

무엇을 예측하는가

Telecom Italia의 공개 밀라노 통신 활동 데이터 중 Internet activity를 사용합니다. 이 값은 10분 구간의 인터넷 관련 통신 활동을 나타내는 수치입니다. 물리적 바이트·MB 또는 실제 접속 건수로 임의 환산하지 않습니다. 따라서 MAE의 단위는 "원 데이터의 활동량 단위"로 표기합니다. 시간 구간의 의미와 활동량 정의는 공개 데이터 설명 [2]를 따릅니다.

어느 셀을 사용하는가

현재 기본 비교의 공간 범위는 중심부 900셀로 고정합니다. 셀 ID는 다음 집합이며 오름차순으로 배열합니다. r과 c는 아래 ID 집합을 생성하기 위한 정수이며 위도·경도가 아닙니다. 논문 [1]은 중심 900셀을 설명하지만 이 정확한 ID 집합은 이번 비교에서 명시한 공통 선택입니다.

```
cell_id = 100*r + c
r = 40, 41, ..., 69;  c = 40, 41, ..., 69
```

예: 4040-4069, 4140-4169, 4240-4269, ..., 6940-6969. 각 구간은 양 끝을 포함하며 총 30×30=900셀입니다. 4040부터 6969까지의 모든 정수를 선택하는 것이 아닙니다. 10,000셀 확장 실험은 공간 범위가 다른 별도 실험으로 구분합니다.

시간대와 행 번호

항목	정확한 정의
표준 저장 시각	UTC 기준 Unix epoch 밀리초, 64비트 정수
날짜·요일 판단	Europe/Rome. 이번 2013년 11월은 UTC+01:00
첫 구간 시작	현지 2013-11-01 00:00 / UTC 2013-10-31 23:00 1383260400000 ms
마지막 구간 시작	현지 2013-11-30 23:50 / UTC 2013-11-30 22:50 1385851800000 ms
전체 배열	시간 4,320행 × 셀 900열. 시간·셀 ID 모두 오름차순
시간 인덱스	t=0부터 4319. timestamp(t)=1383260400000+600000×t

시각은 10분 구간의 시작을 표시합니다

00:00이라는 타임스탬프는 [00:00, 00:10) 구간의 활동량입니다. 마지막 23:50 구간은 다음 날 00:00에 끝납니다. UTC 날짜로 먼저 11월을 자르면 현지 월 경계가 달라지므로, Europe/Rome 기준으로 대상 기간을 선택합니다.

03 전처리: 집계와 정규화

1. 원시 기록에서 셀별 10분 값을 만듭니다

원시 파일은 탭으로 구분된 기록입니다. 공통 처리에 필요한 열은 셀 ID, 시간(밀리초), 국가코드, Internet 값입니다. 0부터 세는 열 번호는 각각 0, 1, 2, 7입니다. 같은 셀·시각에 서로 다른 국가코드의 행이 있을 수 있습니다. [2]

① 동일한 (셀 ID, 시각, 국가코드)가 중복되면 중복 입력 원인을 먼저 해결합니다. 중복 행을 그대로 더하지 않습니다. ② 선택한 900셀과 현지 11월의 10분 격자만 남깁니다. ③ 같은 (셀 ID, 시각)의 유한한 Internet 값들을 국가코드에 걸쳐 합산합니다. ④ 유한한 값이 하나도 없거나 행 자체가 없으면 NaN으로 둡니다.

일부 국가코드만 빈 값이면 나머지 유한한 값의 합을 사용합니다. 유한한 값 0은 관측된 0이며 결측이 아닙니다. 음수나 무한대 값은 데이터 오류로 처리합니다. 국가코드를 평균내거나, SMS·통화 열을 Internet 값에 더하지 않습니다. 이미 10분 자료이므로 시간 평균이나 시간별 재표본화도 하지 않습니다.

2. 셀마다 전체 30일의 최소·최대로 정규화합니다

y[t,i]를 집계된 원 활동량이라고 하겠습니다. 각 셀 i에 대해 t=0,…,4319의 유한한 관측으로 최소 lo_i와 최대 hi_i를 계산합니다. 뒤 10일의 검증·평가 관측도 계수 계산에 포함합니다. 결측은 통계에서 제외하되 원 배열에서는 NaN으로 보존합니다.

```
lo_i = nanmin(y[0:4320, i]);  hi_i = nanmax(y[0:4320, i])
scale_i = hi_i - lo_i
if scale_i <= 1e-12: scale_i = 1
z[t,i] = (y[t,i] - lo_i) / scale_i
y_hat[t,i] = z_hat[t,i] * scale_i + lo_i
```

셀마다 적어도 하나의 유한 관측이 있어야 합니다. 현재 자료의 결측 188개는 보간하지 않습니다. 저장한 원 척도 배열과 계수를 float64로 다루고 역변환·지표도 float64로 계산합니다. 모델 입력·학습에는 float32를 사용할 수 있지만, 정답은 입력 변환값을 다시 복원하지 않고 저장된 원 척도 배열에서 가져옵니다.

전체 30일의 통계를 사용하는 재현 조건입니다

학습 구간의 최소·최대가 10·110이어도 뒤 10일에서 160이 관측되면 전체 기간의 최대는 160이 됩니다. 이때 학습 값 110도 (110-10)/(160-10)으로 변환됩니다. 뒤 10일의 극값이 학습 데이터의 척도에 반영되는 절차를 재현 목적으로 유지합니다. 학습기간만의 정보를 쓰는 미래 예측 조건으로 설명하지 않습니다.

현재 30일의 유한 관측은 정규화 후 0-1 범위에 들어갑니다. 모델 예측은 이 범위나 0 이상으로 임의 제한하지 않습니다. 셀별 lo·scale·상수 셀 여부를 저장해 모든 모델에 동일하게 적용합니다. 추가 로그 변환·이상치 제거·평활화 또는 학습 20일 스케일러를 쓰는 결과는 별도 조건으로 구분합니다.

04 기간 분할과 한 시점 앞 예측

첫 20일 영역: 학습	뒤 10일 영역: 검증·평가 재사용

시간 순서를 유지하며 타깃 시각으로 분할합니다. 아래는 제공 코드의 창 구성과 오프셋을 보존한 실제 경계입니다. 달력상 20일/10일의 모든 타깃을 사용한다는 뜻은 아닙니다.

용도	타깃의 현지 시각	0-based 타깃 인덱스
학습	11/01 01:20 - 11/20 22:30	8 ≤ t < 2872
검증	11/21 01:20 - 11/30 23:50	2888 ≤ t < 4320
평가	11/21 02:10 - 11/30 23:50	2893 ≤ t < 4320

입력 길이 8로 인해 첫 학습 타깃은 11/01 01:20입니다. 제공 구현은 학습 영역 끝의 8개 타깃도 사용하지 않고, 검증을 21일 01:20부터 시작합니다. 평가는 검증보다 5시점(50분) 늦게 시작합니다. 이 경계를 그대로 고정하며 누락 타깃을 임의 복원하지 않습니다.

```
X[t,i] = [z[t-8,i], ..., z[t-1,i]]
target[t,i] = z[t,i]       # one next 10-minute interval
```

경계 시점의 구체적인 예

타깃 구간 시작	사용할 실제 관측 구간의 시작 시각
11/01 01:20	11/01 00:00, 00:10, ..., 01:10
11/21 01:20 (검증 첫 타깃)	11/21 00:00, 00:10, ..., 01:10
11/21 02:10 (평가 첫 타깃)	11/21 00:50, 01:00, ..., 02:00

각 예측은 해당 타깃 구간이 시작되기 직전에 수행한다고 가정합니다. 앞선 8개 구간의 실제 관측은 이미 알 수 있습니다. 다음 시점에는 새로 관측된 실제 값을 입력에 넣습니다. 이전 예측값을 되먹임하는 다단계 재귀 예측과는 다른 과제입니다.

검증·평가 구간의 과거 관측을 입력으로 사용하는 범위

예측 입력 창은 t 이전의 실제 관측 8개입니다. 앞선 평가 타깃도 이미 관측된 뒤에는 다음 창의 입력이 됩니다. 모델 가중치의 경사 업데이트는 학습 타깃에서 수행합니다. 다만 정규화에는 전체 30일 통계를 쓰고, checkpoint 선택에는 뒤 10일의 검증 정답을 사용한다는 예외를 함께 기록합니다.

평가는 검증의 부분집합입니다

검증에서 설정·checkpoint를 선택한 뒤 같은 뒤 10일 영역을 평가합니다. 검증 첫 5개 타깃만 평가에서 빠지므로 두 집합은 완전히 같지는 않지만 겹칩니다. 검증용과 독립 평가용의 5일씩 구간을 만들지 않습니다. 이 점수는 제공 절차를 따른 재현 비교이며 독립 시험의 일반화 성능은 아닙니다.

비교 후보·시드·탐색 예산·선택 규칙은 실행 전에 정하고 모든 시도와 선택을 기록합니다. 별도 평가 결과를 본 뒤 유리한 실행만 남기지 않습니다. 미니배치 순서를 섞을 수 있지만 시간축 자체를 무작위 분할하지 않습니다.

05 결측 처리와 공통 평가 표본

표본의 유효성은 데이터만으로 먼저 정합니다

셀 i, 타깃 t의 입력 8개와 정답 1개가 모두 유한한 경우에만 그 표본을 사용합니다. 이 조건을 valid_q8이라고 부릅니다. 마스크는 모델이나 예측값과 무관하게 같은 원자료에서 한 번 계산합니다.

```
valid_q8[t,i] = all(isfinite(y[t-8:t+1, i]))
mape_eligible[t,i] = valid_q8[t,i] and (y[t,i] > 0)
```

NaN을 0으로 바꾸지 않고 앞뒤 값 보간, 전방 채우기, 후방 채우기도 하지 않습니다. 결측 행을 시간축에서 삭제한 뒤 남은 행을 이어 붙이면 10분 간격이 깨지므로, 전체 시간축은 유지하고 해당 창만 제외합니다.

현재 900셀 기준 자료의 확인값

구간	후보 표본	유효 표본	제외
학습	2,577,600	2,577,600	0
검증	1,288,800	1,288,238	562
평가	1,284,300	1,283,738	562

학습 후보는 (2872-8)×900, 검증은 1432×900, 평가는 1427×900입니다. 검증과 평가가 겹치므로 세 수를 독립 표본의 총수처럼 합산하지 않습니다. 원자료의 결측 셀-시점은 188개이며 11/29에 92개, 11/30에 96개입니다. 겹치는 입력 창에 결측의 영향이 퍼지므로 188과 562는 서로 다른 수입니다.

898셀은 검증 1,432개·평가 1,427개가 유효합니다. 결측이 있는 2개 셀도 포함하며, 각각 검증 1,151개·평가 1,146개가 유효합니다. 따라서 검증에서도 셀별 유효 표본 수가 같지 않습니다.

현재 기준 배열의 유한한 값에는 정확히 0인 타깃이 없습니다. 다른 규모·버전의 자료에서도 계산 규칙을 유지할 수 있도록 0 처리 규칙은 06절에 명시합니다. 위 수치는 논문에 보고된 결측 통계가 아니라 공통 기준 데이터의 재검산값입니다.

예측 실패 때문에 평가 표본을 줄이면 안 됩니다

valid_q8=True인 표본에서 NaN·무한대 예측 또는 예측 누락이 생기면 실행 실패로 보고합니다. 그 행만 삭제해서 점수를 낮추지 않습니다. 모든 방법은 같은 900셀·마스크를 사용하며, 저활동량이나 큰 오차를 이유로 셀을 사후 제외하지 않습니다. 기본 비교를 완료하려면 모든 유효 타깃에 예측이 있어야 합니다.

더 긴 입력 길이를 쓰면 필요한 과거 범위와 결측 마스크도 달라집니다. 이 결과는 입력 길이 8의 기본 비교와 별도 표로 제시하고, 바뀐 입력·표본 수·마스크를 공개해야 합니다.

06 평가 지표: 원 척도와 셀별 평균

정규화된 예측은 먼저 저장한 셀별 계수로 역변환합니다. 아래 y와 pred는 모두 원 활동량 척도이며 float64로 계산합니다. V_i는 셀 i의 유효 평가 시점, V_i+는 그중 y>0인 시점입니다. macro는 셀별 점수를 먼저 구한 뒤 셀을 동일 가중합니다.

```
MAE_i = mean(abs(y - pred))                 # t in V_i
MAPE_i_ratio = mean(abs(y-pred) / y)         # t in V_i+
macro_MAE = mean(MAE_i)                     # equal cells
macro_MAPE_ratio = mean(MAPE_i_ratio)       # eligible cells
micro_MAE = sum(abs(y-pred)) / total_valid_rows
micro_MAPE_ratio = sum(abs(y-pred)/y) / total_positive_rows
macro_MAPE_percent = 100 * macro_MAPE_ratio
micro_MAPE_percent = 100 * micro_MAPE_ratio
```

micro MAE의 합은 모든 V_i, micro MAPE의 합은 모든 V_i+에 대해 계산합니다. micro MAPE의 분모는 MAPE 대상 양수 타깃 수이며, 0 타깃을 포함한 전체 유효 행 수가 아닙니다.

주지표와 보조지표

주 보고지표는 raw micro MAPE(%)이며 micro MAE를 함께 우선 제시합니다. macro MAPE(%)와 macro MAE도 반드시 병기합니다. 제공 평가 파일의 활성 최종 출력은 전체 표본을 모은 micro 집계입니다. 셀마다 같은 비중을 주는 macro와 표본마다 같은 비중을 주는 micro는 결측 수가 다르면 달라집니다. 임의 그룹의 평균을 다시 평균내지 않습니다.

현재 저장 예측은 float64로 채점합니다. 제공 코드의 float32 역변환·순차 누적과는 작은 수치 차이가 있을 수 있습니다. 집계 정의를 맞추는 것과 연산까지 비트 단위로 같다는 주장은 구분합니다.

0 타깃, 작은 값, 잘못된 예측

정답 0은 MAE에 포함하고 MAPE에서만 제외합니다. 분모에 epsilon을 더하거나 작은 양수 정답을 임의로 제외하지 않습니다. 양수 타깃이 없는 셀은 macro MAPE에서 제외하고 해당 셀 수를 보고합니다. 전체에 양수 타깃이 없으면 두 MAPE 모두 미정의입니다. 음수 타깃은 데이터 오류이고, 음수 예측은 자르지 않고 그대로 오차를 계산합니다.

손으로 확인할 수 있는 계산 예

셀	유효 정답 → 예측	MAE	MAPE
A	1→0, 2→3 (2개 표본)	1.0	75%
B	0→1, 4→2, 6→9 (3개 표본)	2.0	50%

A의 상대오차는 1과 0.5, B의 양수 타깃 상대오차는 0.5와 0.5입니다. macro MAPE=62.5%, micro MAPE=100×(1+0.5+0.5+0.5)/4=62.5%입니다. 이 예는 두 셀의 양수 타깃 수가 같아 MAPE 집계가 일치합니다. macro MAE=1.5, micro MAE=(1+1+1+2+3)/5=1.6입니다.

0.10과 0.10%는 서로 다릅니다

MAPE 비율 0.10은 10%입니다. macro/micro 각각의 비율과 %를 함께 저장하고 열 제목에 집계와 단위를 표시합니다. 소수점 반올림은 모든 계산을 끝낸 뒤 표시 단계에서만 수행합니다.

07 모델 선택과 반복 실험의 공정성

공통으로 고정할 것과 모델별로 기록할 것

구분	운영 규칙
공통으로 고정	셀·기간·타깃 시각, 입력 길이 8, 정규화 계수, 결측 마스크, 평가식, 반복 시드
모델별로 정하고 공개	모델명·버전·구조, 학습률·배치 크기·손실, 학습 예산·종료 규칙, 탐색한 설정 수, 사전학습 여부
기본 비교의 예측 입력	대상 셀의 직전 8개 Internet 관측값. 학습에는 같은 900셀의 학습기간을 사용할 수 있음
추가 정보 조건	다른 셀의 예측 입력, 외생변수, 더 긴 입력, 사전학습·온라인 갱신은 사용 범위를 공개하고 기본 조건과 구분

모델 학습 가중치의 업데이트에는 04절의 학습 타깃을 사용합니다. 입력에는 타깃 시점의 실제 값을 넣지 않습니다. 숨은 상태·캐시도 직전 8개 입력 조건에 맞춥니다. 정규화에 한해 전체 30일의 min/max를 사용하며, 별도 학습형 변환·추가 특징의 적합 범위는 명시하고 기본 조건과 구분합니다.

겹치는 검증 구간으로 checkpoint를 선택합니다

공통 선택 점수는 각 학습 모델에 속한 유효 검증표본 전체의 정규화 MAE(val_loss)입니다. 셀 평균을 다시 평균내지 않습니다. 최솟값의 설정·checkpoint를 선택하고 epoch 간 정확한 동률이면 이른 epoch를 사용합니다. 평가 전에 선택한 가중치를 명시적으로 복원합니다. 검증 표본 수도 셀마다 달라 macro와 같다고 가정할 수 없습니다.

현재 학습의 val_loss는 float32 경로이며, 최종 보고용 원 척도 float64 오차와 구분합니다. 학습 손실·선택 지표·학습 예산·종료 규칙·탐색 횟수를 사전 기록합니다. 모델별 학습률·배치 크기는 공개하되 일률적으로 강요하지 않습니다. 추가 탐색이나 검증까지 합친 재학습은 별도 조건으로 기록합니다.

시드 53·54·55로 대응시켜 보고합니다

각 확률적 모델을 시드 53, 54, 55에서 반복합니다. 매번 난수 생성기와 모델·optimizer 상태를 초기화합니다. 같은 시드끼리 차이를 계산하고 시드별 값·3회 평균·표본 표준편차(ddof=1)를 보고합니다. 우수한 시드만 골라 평균을 대체하지 않습니다. 추가 시드는 목록을 먼저 정해 비교 모델에 같이 적용합니다.

서로 다른 구조에서 같은 시드는 같은 초기 가중치를 뜻하지 않습니다. 동일 구조를 비교할 때는 가능한 경우 같은 시드의 초기 가중치를 공유하고 그 여부를 기록합니다. 같은 시드가 GPU의 비트 단위 재현성까지 보장하지는 않습니다.

시드 점수 평균과 예측 평균 앙상블을 구분합니다

세 번 계산한 오차의 평균과, 세 예측을 표본별로 평균한 뒤 계산한 오차는 서로 다른 값입니다. 앙상블은 별도 실행 ID로 보고하고, 구성 모델·시드·가중치를 검증에서 고정합니다. 제안법이 앙상블이면 같은 구성 수·예측 집합을 사용한 단순 평균 기준과도 비교합니다.

3시드는 한 평가기간의 학습 무작위성 반복이며 독립된 3개 기간이나 자동으로 성립하는 99% 신뢰구간이 아닙니다. 결정적 모델의 동일 결과를 재사용했다면 실행 수와 재사용 수를 구분합니다.

08 팀 간 결과 교환 형식

예측 결과는 셀·타깃 시각으로 연결합니다

모델마다 다음 열을 가진 긴 형식의 CSV 또는 동등한 테이블을 저장합니다. 평가 후보 전체 1,284,300행을 실행마다 유지하면 결측 처리를 대조하기 쉽습니다. 유효 예측은 정확히 1,283,738행이어야 합니다. 행 키는 (protocol_id, run_id, cell_id, timestamp_utc_ms)이며, run_id는 모델·설정·시드 또는 앙상블 구성을 유일하게 식별합니다.

필드	의미와 규칙
protocol_id, run_id	데이터·분할·집계 규칙의 버전과 개별 실행 식별자
model_id, config_id	모델과 확정 설정. 구조·소프트웨어 버전은 실행 명세에 기록
seed, ensemble_id, split	단일 실행은 시드 53/54/55. 앙상블은 별도 ID와 구성 목록. split은 evaluation 등 구간명
cell_id	원래 셀 ID. 배열 열 번호로 대신하지 않음
timestamp_utc_ms	예측할 구간의 시작 시각. 정수 밀리초이며 입력 마지막 시각이 아님
y_true_raw	집계 후 정규화 이전의 원 척도 정답. 결측이면 빈 필드와 마스크로 표시
y_pred_raw	동일 원 척도의 예측. 유효 표본에서 누락·NaN·무한대 금지
valid_q8, mape_eligible	입력 8개+타깃 유한성 / valid_q8=True이며 y_true_raw>0

요약 결과와 실행 명세

시드별 micro MAPE(비율·%)와 micro MAE를 먼저 제시하고 macro MAPE(비율·%)와 macro MAE를 함께 저장합니다. 유효 행·양수 타깃·포함 셀·0 타깃 수와 셀별 표본 수·오차도 저장합니다. 시드 점수 평균·표본 표준편차와 앙상블 점수는 별도 행으로 표시합니다.

같은 조건의 기준 모델과 같은 시드끼리 차이를 계산합니다. MAPE(%) 차이는 퍼센트포인트(%p), 상대 개선율은 %로 구분합니다. 상대 개선율=(기준 오차-제안 오차)/기준 오차×100이며, 기준 오차가 0이면 미정의입니다. 데이터·분할·집계 조건이 다른 점수로 개선율을 계산하지 않습니다. 단일 모델 대비 개선과 동일 예측 집합의 단순 평균 앙상블 대비 추가 개선을 구분해 보고합니다.

실행 명세에는 전체 30일 scaler fit, 04절 타깃 경계, independent_test=false, 데이터·ID·시각·스케일러·마스크 해시, 코드·가중치 버전, 선택 점수·epoch, 시드·환경·실패·재시도·재사용 여부를 기록합니다. 앙상블 구성과 가중치도 기록합니다. 파일 형식이 다르면 해시 외에 배열값·ID·시각의 동등성을 대조합니다.

시간·메모리 비교

전처리, 모델 준비·학습, 예측과 파일 입출력 시간 및 전체 비용을 보고합니다. 같은 장비·측정 구간에서 비교하며 GPU는 작업 완료를 동기화한 뒤 시간을 멈춥니다. 첫 실행과 캐시 재사용을 구분합니다. GPU 전용 메모리와 시스템 RAM을 따로 기록하고 공유 메모리를 전용 VRAM에 더하지 않습니다. 다른 장비의 논문 시간으로 직접 속도 우위를 계산하지 않습니다.

09 참고 구현: 분할·창·평가

모델과 독립된 NumPy 참조 계산입니다. y는 원 척도 배열(4320,900), pred_raw는 평가기간의 원 척도 예측 배열(1427,900)입니다. 전체 30일 스케일러와 제공 코드의 타깃 경계를 적용합니다.

```
import numpy as np
# 1) All-30-day scaling; preserve the full timeline.
y = np.asarray(y, dtype=np.float64)
assert y.shape == (4320, 900) and not np.isinf(y).any()
assert np.isfinite(y).any(axis=0).all()
assert (y[np.isfinite(y)] >= 0).all()
lo = np.nanmin(y, axis=0)
scale = np.nanmax(y, axis=0) - lo
constant = scale <= 1e-12
scale[constant] = 1.0
z = (y - lo) / scale
# 2) Target t uses exactly t-8, ..., t-1.
def get_samples(a, b):
    ts, cells, xs, ys = [], [], [], []
    for t in range(a, b):
        good = np.isfinite(y[t-8:t+1]).all(axis=0)
        for i in np.flatnonzero(good):
            ts.append(t); cells.append(i)
            xs.append(z[t-8:t, i]); ys.append(z[t, i])
    return ts, cells, np.asarray(xs), np.asarray(ys)
# Train (8,2872), validation (2888,4320), eval (2893,4320).
# Evaluation is a subset of validation, not an independent test.
# Keep cell_ids[cells] and timestamps[ts] with each sample.
# 3) Invert with saved coefficients; score original raw y.
# pred_raw = np.asarray(pred_scaled, dtype=np.float64) * scale + lo
pred_raw = np.asarray(pred_raw, dtype=np.float64)
truth = y[2893:4320]
mask = np.isfinite(truth).copy()
for lag in range(1, 9):
    mask &= np.isfinite(y[2893-lag:4320-lag])
assert mask.sum() == 1283738
assert pred_raw.shape == truth.shape
assert np.isfinite(pred_raw[mask]).all()
# 4) Equal-cell macro and pooled micro metrics.
err = np.zeros_like(truth)
err[mask] = np.abs(truth[mask] - pred_raw[mask])
count = mask.sum(axis=0)
assert (count > 0).all()
mae_cell = err.sum(axis=0) / count
positive = mask & (truth > 0)
npos = positive.sum(axis=0)
relative = np.zeros_like(truth)
relative[positive] = err[positive] / truth[positive]
ratio_cell = np.divide(relative.sum(axis=0), npos,
    out=np.full(900, np.nan), where=npos > 0)
eligible = npos > 0
macro_mape_ratio = (ratio_cell[eligible].mean()
                    if eligible.any() else np.nan)
micro_mape_ratio = (relative.sum() / npos.sum()
                    if npos.sum() > 0 else np.nan)
macro_mape_pct = 100 * macro_mape_ratio
micro_mape_pct = 100 * micro_mape_ratio
macro_mae = mae_cell.mean()
micro_mae = err.sum() / mask.sum()
```

단순 반복문은 이해를 위한 것입니다. 벡터화·배치 처리로 바꿔도 (셀 ID, 타깃 시각), 입력 창, 마스크와 네 지표가 같아야 합니다. 제외 사유·분모·셀별 결과·저장 계수도 함께 보존합니다.

10 논문과의 대응 및 실행 확인표

논문의 내용 [1]	이번 비교 기준에서의 적용
첫 30일, 10분 간격, 셀당 4,320시점 IV-A, 인쇄 6265쪽	2013년 11월, 현지 시각 기준의 완전한 10분 격자로 고정
중심 900셀 및 전체 10,000셀 실험 IV-A, 인쇄 6265쪽	현재 900셀의 정확한 ID를 02절에 고정. 10,000셀은 별도 규모
첫 20일 학습, 뒤 10일 검증·테스트 IV-A, 인쇄 6265쪽	뒤 10일을 검증·평가에 재사용. 5/5로 나누지 않으며 실제 경계는 04절 적용
기본 입력 길이 q=8, 간격 10분 Table I와 본문, 인쇄 6266쪽	직전 8개 관측으로 다음 10분 값 1개 예측. 경계 이전의 과거 입력 허용
MAPE 식(2), MAE 식(3) 인쇄 6265-6266쪽	원 척도 macro/micro MAPE·MAE. 집계·0값·결측·반복은 이 문서에서 명시

확인된 제공 구현: 전체 30일 min/max 정규화, 뒤 10일의 검증 손실에 따른 checkpoint 선택, 같은 뒤 10일 영역 평가, 최종 micro 집계입니다. 현재 타깃 경계는 학습 끝 8개 누락과 평가 시작 5시점 오프셋도 보존합니다. 이는 제공 파일과 현재 재현 코드에서 확인한 사실입니다.

미확정 사항: 저자의 최종 입력 CSV, 실제 최종 타깃 목록·결측 처리, 최종 checkpoint와 논문 점수의 연결, 반복·선정·신뢰구간 산출 방법입니다. 논문이 뒤 10일을 검증·테스트로 설명하는 것과 최종 실행에서 정확히 어떤 표본을 재사용했는지가 확인된 것은 구분합니다. 현재 명시한 결측·0값·float64·시드 규칙도 원저자의 확인값 전체를 뜻하지 않습니다.

제공 절차에 맞춘 재현 비교로 해석합니다

전체 30일 통계와 겹치는 검증·평가 표본을 사용하므로 독립 미래 시험의 성능으로 설명하지 않습니다. 논문 점수와 차이를 보고할 수 있지만, 수치 근접만으로 정확 재현을 확정하지 않습니다. 모델 간 개선율은 같은 데이터·스케일러·타깃·마스크·집계 조건으로 실행한 결과끼리 계산합니다. 독립 검증이 필요하면 별도 프로토콜로 구분합니다.

실행 전과 결과 수합 때 확인할 사항

① 900개 ID·4,320시점·시간대가 같은가? ② 전체 30일 스케일러인가? ③ 04절의 타깃 경계와 입력 창이 같은가? ④ 평가 후보 1,284,300개·유효 1,283,738개인가? ⑤ micro 우선 네 지표와 분모를 저장했는가? ⑥ 검증·평가 중복과 선택 규칙을 기록했는가? ⑦ 시드별 예측·선택 가중치·앙상블 구성·실행 비용을 보존했는가?

참고문헌

[1] H. Yang, J. Park, S. M. Raza, M. Kim, M. Y. Chung, H. Choo. “Urban Mobile Data Prediction With Geospatial Clustering and Dual Residual Learning.” IEEE Transactions on Network and Service Management, 22(6), 6260-6273, 2025. DOI: 10.1109/TNSM.2025.3599168.

https://doi.org/10.1109/TNSM.2025.3599168

[2] G. Barlacchi et al. “A multi-source dataset of urban life in the city of Milan and the Province of Trentino.” Scientific Data 2, 150055, 2015. Methods / Telecommunications activity / Data Records. DOI: 10.1038/sdata.2015.55.

https://www.nature.com/articles/sdata201555